

PREDIKSI KETERLAMBATAN PENGIRIMAN PADA DATACO SMART SUPPLY CHAIN MENGGUNAKAN MACHINE LEARNING



Final FESMARO 2025 - Analisis Big Data

**Ketua Tim: Syifa Azzahirah
Politeknik Negeri Jakarta**

ANGGOTA KELOMPOK

**Syifa
Azzahirah**



**Deva Alvyn
Budinugraha**



**Nabil Falih
Khairullah**




PEMAHAMAN MASALAH

Keterlambatan pengiriman dalam rantai pasok dapat berdampak pada reputasi, efisiensi biaya, dan kepuasan pelanggan. Karena banyaknya faktor yang terlibat dan tingginya kompleksitas data, perusahaan memerlukan pendekatan berbasis teknologi untuk memprediksi risiko keterlambatan secara akurat dan lebih awal.




TUJUAN PENELITIAN



Menganalisis faktor-faktor utama yang mempengaruhi keterlambatan pengiriman.



Membangun model Machine Learning untuk memprediksi apakah sebuah pesanan akan mengalami keterlambatan atau tidak.




Memberikan insight dan rekomendasi bagi perusahaan untuk mengurangi risiko keterlambatan dan meningkatkan efisiensi rantai pasok.

RANCANGAN PROSES ANALITIKA

- **Eksplorasi Data** untuk memahami pola awal keterlambatan.
- **Preprocessing**, termasuk penghapusan duplikat, handling missing values, encoding variabel kategorikal, dan normalisasi data numerik.
- **Feature Engineering**, menciptakan fitur baru seperti Shipment_Delay serta mengekstrak Order Day dan Order Month.
- **Pelatihan Model**, dengan algoritma utama: Random Forest dan XGBoost.
- **Evaluasi Model**, menggunakan metrik: Accuracy, Precision, Recall, F1-Score, Confusion Matrix, ROC-AUC Curve.
- **Interpretasi Model**, dilakukan dengan feature importance dan kurva ROC.



ALAT DAN PUSTAKA



seaborn




Algoritma: Random Forest dan XGBoost

DATA OVERVIEW

Analisis ini berfokus pada prediksi keterlambatan pengiriman dalam rantai pasok menggunakan dataset **DataCo Smart Supply Chain** yang diperoleh dari Kaggle menggunakan structured data dari **DataCoSupplyChainDataset.csv** yang berisi informasi transaksi dan logistik, seperti waktu pemesanan, lokasi pengiriman, metode pembayaran, jenis produk, dan status keterlambatan pengiriman.

180,519 ROWS

53 COLUMNS



MENGHAPUS KOLOM TIDAK INFORMATIF

PRODUCT
DESCRIPTION

ORDER
ZIPCODE

CUSTOMER
EMAIL

CUSTOMER
FNAME

CUSTOMER
LNAME

CUSTOMER
PASSWORD

CUSTOMER
STREET

CATEGORY
ID

ORDER
CUSTOMER ID

BENEFIT PER
ORDER

SALES PER
CUSTOMER

ORDER ITEM
PRODUCT PRICE

ORDER ITEM
CARDPROD ID

PRODUCT
IMAGE

PRODUCT
STATUS


ORDER ITEM
ID

Lalu, untuk seluruh data numerik yang memiliki nilai hilang (missing values) diisi dengan **median**.

FEATURE ENGINEERING (1)

- **Fitur Baru:**
 - **Shipment_Delay:** Selisih antara tanggal pengiriman aktual dan terjadwal.
 - **Late_Delivery:** Label target biner berdasarkan apakah pengiriman terlambat (Shipment_Delay > 0).
- **Ekstraksi Waktu:**
 - Dipecah dari kolom Order Date menjadi Order Year, Order Month, dan Order Day untuk analisis pola musiman permintaan.
- **Seleksi Fitur:**
 - Fitur yang dipilih mencakup informasi pengiriman, lokasi pelanggan, dan kategori produk.

DISTRIBUSI LATE DELIVERY



- Data menunjukkan bahwa **mayoritas pengiriman mengalami keterlambatan** (label 1).
- Jumlah pengiriman terlambat lebih dari **105.000** sedangkan yang tepat waktu sekitar **77.000**.
- Artinya, dataset ini **sedikit tidak seimbang**, namun masih bisa ditangani tanpa teknik balancing ekstrem.
- Insight ini memperkuat urgensi penggunaan **model prediktif** untuk mendeteksi keterlambatan sejak awal.

FEATURE ENGINEERING (2)


- **Transformasi Data:**

- Fitur kategorikal seperti Shipping Mode, Customer City, Order Region, dan Category Name dikonversi menggunakan **One-Hot Encoding**.
- Fitur numerik seperti Order Year, Month, dan Day dinormalisasi menggunakan **StandardScaler**.

- **Output Akhir:**


- Dataset siap modeling disimpan sebagai FF_processed_dataset.csv, dan dilakukan split data untuk pelatihan model.

CORRELATION HEATMAP




- Mayoritas fitur menunjukkan **korelasi rendah** satu sama lain → mengindikasikan **minim multikolinearitas**, cocok untuk model machine learning.
- Banyak fitur hasil **one-hot encoding** seperti Shipping Mode, Customer City, Order Region, dan Category Name → membuat fitur bersifat **saling eksklusif** dan tidak saling memengaruhi.
- Korelasi tinggi hanya muncul di diagonal (fitur dengan dirinya sendiri), hal ini **normal dan tidak jadi fokus analisis**.
- Secara umum, **fitur hasil encoding aman digunakan** dan dapat dilanjutkan ke tahap modeling.

PERBANDINGAN AKURASI




- **Random Forest** memiliki akurasi **81.49%**, lebih unggul dibanding **XGBoost** yang mencapai **71.71%**.
- Model Random Forest menjadi kandidat utama karena performa konsisten dan akurasi tinggi.

CONFUSION MATRIX (1)




- Prediksi benar: **12.559 (kelas 0)** dan **16.862 (kelas 1)**
- Model ini **cukup seimbang** dalam mendeteksi keterlambatan dan pengiriman tepat waktu.

CONFUSION MATRIX (2)




- Prediksi benar: **13.600 (kelas 0)** dan **12.291 (kelas 1)**
- Model cenderung **lebih banyak false negative**, yaitu gagal mendeteksi keterlambatan (8.414 kasus).

FEATURE IMPORTANCE (1)




- Fitur paling berpengaruh: **Order Day**, **Shipping Mode**, dan **Order Month**.
- Artinya, **waktu pemesanan** dan **jenis pengiriman** sangat memengaruhi kemungkinan keterlambatan.

FEATURE IMPORTANCE (2)




- Fitur paling penting: **Shipping Mode** (First & Standard Class).
- Fokus utama model ini ada pada **jenis layanan pengiriman**, namun sensitivitasnya terhadap waktu lebih rendah dibanding RF.

ROC-AUC CURVE




- Random Forest memiliki skor **AUC = 0.88**, jauh lebih baik dibanding XGBoost (AUC = 0.78).
- Ini menegaskan **kemampuan prediksi Random Forest lebih unggul secara keseluruhan.**

OOB ERROR ANALYSIS



- Jumlah pohon optimal berada di kisaran **100-200**, dengan OOB error menurun drastis dari awal dan **stabil setelah 100 trees**.
- Ini menunjukkan **stabilitas model dan performa yang tidak overfitting** saat jumlah estimators bertambah.

HASIL PROSES ANALITIKA



Prediksi: Pengiriman TIDAK AKAN TERLAMBAT dengan probabilitas 73.00%.

Visualisasi ini menunjukkan bahwa model Random Forest memprediksi pesanan ini **tidak akan mengalami keterlambatan** dengan tingkat keyakinan sebesar **73%**. Hal ini menunjukkan kecenderungan model untuk memberikan prediksi yang konservatif, namun tetap memperhatikan potensi **risiko keterlambatan** sebesar **27%**.

INSIGHT DAN REKOMENDASI

Kesimpulan

- **Random Forest** terbukti sebagai model terbaik dengan akurasi mencapai **81.49%** dalam memprediksi keterlambatan pengiriman.
- Fitur Shipment_Delay berkontribusi besar terhadap performa model.
- Model ini dapat membantu perusahaan **meningkatkan efisiensi operasional** dan **mengurangi risiko keterlambatan** pengiriman barang ke pelanggan.

Rekomendasi Pengembangan

- Lakukan **Hyperparameter Tuning** (misalnya dengan GridSearchCV) untuk meningkatkan akurasi model lebih lanjut.
- Tambahkan variabel eksternal seperti **cuaca**, **lalu lintas**, dan **hari libur** agar model lebih kontekstual dan akurat.
- Integrasikan model ke dalam **dashboard interaktif** agar tim operasional dapat memantau status risiko keterlambatan secara real-time.

KESIMPULAN

Dengan memanfaatkan pendekatan machine learning berbasis Random Forest, kami tidak hanya berhasil memprediksi keterlambatan pengiriman dengan akurasi tinggi, tapi juga membuka peluang nyata bagi perusahaan untuk mengubah tantangan logistik menjadi strategi cerdas. Model ini bukan sekadar prediksi—ini adalah langkah awal menuju operasional yang lebih efisien, responsif, dan unggul dalam kompetisi pasar.



ARE THERE ANY QUESTIONS?



Click here to open the code!

[Notebook](#) | [Github](#)